## ETS DATA MINING TAKE HOME

NO. 4. Lakukan nalisis Association Rule menggunakan alogaritma apriori pada data Online Retail. Diperbolehkan menggunakan bantuan software. Data tersedia di link berikut. https://intip.in/etsdatmin2

Dalam data Online Retail tersebut terdapat 8 Variabel, yaitu Invoice No, Stock Code, Description, Quantity, Invoice Date, Unit Price, Customer dan Country. Dengan keterangan sebagai berikut:

- a. Invoice No merupakan nomor nota pada setiap pembelian,
- b. Stock Code merupakan kode stok dari sebuah barang,
- c. Decription yaitu deskripsi dari barang,
- d. Quantity merupakan jumlah barang yang dibeli pada sebuah transaksi,
- e. Invoice Date adalah tanggal pembelian,
- f. Unit Price adalah harga per unit barang,
- g. Customer ID adalah ID pelanggan,
- h. Country adalah negara pelanggan.

Berikut merupakan output dari Jupyter Notebook beserta Syntax nya

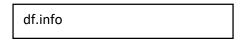
import pandas as pd

df = pd.read\_excel(r'E:/ets2.xlsx', sheet\_name='Sheet1')

df.head()

	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
0	536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	2010-01-12 08:26:00	2.55	17850.0	United Kingdom
1	536365	71053	WHITE METAL LANTERN	6	2010-01-12 08:26:00	3.39	17850.0	United Kingdom
2	536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	2010-01-12 08:26:00	2.75	17850.0	United Kingdom
3	536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6	2010-01-12 08:26:00	3.39	17850.0	United Kingdom
4	536365	84029E	RED WOOLLY HOTTIE WHITE HEART.	6	2010-01-12 08:26:00	3.39	17850.0	United Kingdom

Gambar di atas merupakan tampilan data Online Retail yang terdiri dari 8 Variabel yaitu Invoice No, Stock Code, Description, Quantity, Invoice Date, Unit Price, Customer dan Country.



[541909 rows x 8 columns]

Data Online Retail terdiri dari 8 kolom dan 541909 baris. Kemudian akan dilihat apakah terdapat missing value atau tidak.

```
## imputation missing value
import numpy as np
np.sum(df.isnull())
```

```
InvoiceNo 0
StockCode 0
Description 1454
Quantity 0
InvoiceDate 0
UnitPrice 0
CustomerID 135080
Country 0
dtype: int64
```

Berdasarkan output di atas, diketahui bahwa terdapat 1454 missing value pada variabel Description dan sebanyak 135080 pada Variabel Customer ID.

from mlxtend.frequent\_patterns import apriori from mlxtend.frequent\_patterns import

Dilakukan import Package atau import library, namun library mlxtend tidak dapat diinstal/ tidak kompantibel dengan python yang digunakan.

Description InvoiceNo	10 COLOUR SPACEBOY PEN	12 COLOURED PARTY BALLOONS	12 EGG HOUSE PAINTED WOOD	12 MESSAGE CARDS WITH ENVELOPES	12 PENCIL SMALL TUBE WOODLAND	12 PENCILS SMALL TUBE RED RETROSPOT	12 PENCILS SMALL TUBE SKULL
536370	0.0	0.0	0.0	0.0	0.0	0.0	0.0
536852	0.0	0.0	0.0	0.0	0.0	0.0	0.0
536974	0.0	0.0	0.0	0.0	0.0	0.0	0.0
537065	0.0	0.0	0.0	0.0	0.0	0.0	0.0
537463	0.0	0.0	0.0	0.0	0.0	0.0	0.0
5 rows × 156	3 columns						

Pada gambar di atas telah dilakukan pembersihan data pada variabel description dan menghilangkan data yang memiliki invoice tidak valid

# Show a subset of columns

basket.iloc[:,[0,1,2,3,4,5,6,7]].head()

Description InvoiceNo	COLOUR SPACEBOY PEN	12 COLOURED PARTY BALLOONS	12 EGG HOUSE PAINTED WOOD	MESSAGE CARDS WITH ENVELOPES	12 PENCIL SMALL TUBE WOODLAND	12 PENCILS SMALL TUBE RED RETROSPOT	PENCILS SMALL TUBE SKULL
536370	0.0	0.0	0.0	0.0	0.0	0.0	0.0
536852	0.0	0.0	0.0	0.0	0.0	0.0	0.0
536974	0.0	0.0	0.0	0.0	0.0	0.0	0.0
537065	0.0	0.0	0.0	0.0	0.0	0.0	0.0
537463	0.0	0.0	0.0	0.0	0.0	0.0	0.0

```
# Convert the units to 1 hot encoded values

def encode_units(x):
    if x <= 0:
        return 0
    if x >= 1:
        return 1

basket_sets = basket.applymap(encode_units)
# No need to track postage

basket_sets.drop('POSTAGE', inplace=True, axis=1)
basket_sets.head()
```

Description	10 COLOUR SPACEBOY PEN	12 COLOURED PARTY BALLOONS	12 EGG HOUSE PAINTED WOOD	MESSAGE CARDS WITH ENVELOPES	12 PENCIL SMALL TUBE WOODLAND	12 PENCILS SMALL TUBE RED RETROSPOT	12 PENCILS SMALL TUBE SKULL
InvoiceNo							
536370	0	0	0	0	0	0	0
536852	0	0	0	0	0	0	0
536974	0	0	0	0	0	0	0
537065	0	0	0	0	0	0	0
537463	0	0	0	0	0	0	0
5 rows × 156	32 columns						

Kemudian dilakukan pengkodean, jika x <= 0, maka dikoding 0 dan jika x >= 1 maka dikoding 1

```
# Build up the frequent items# Build

frequent_itemsets = apriori(basket_sets, min_support=0.07, use_colnames=True)

frequent_itemsets.head()
```

```
NameError

ipython-input-22-f20b5b441eb6> in <module>()

i # Build up the frequent items# Build

---> 2 frequent_itemsets = apriori(basket_sets, min_support=0.07, use_colname s=True)

NameError: name 'apriori' is not defined
```

Frekuensi itemset tidak dapat diketahui sebab Apriori tidak dapat digunakan karena package mlextend tidak dapat diinstall.

```
# Create the rules# Create

rules = association_rules(frequent_itemsets, metric="lift", min_threshold=1)

rules
```

```
NameError

Traceback (most recent call last)

<ipython-input-24-7f5690a745b0> in <module>()

1 # Create the rules# Create
---> 2 rules = association_rules(frequent_itemsets, metric="lift", min_thresh
old=1)

3 rules

NameError: name 'association_rules' is not defined
```

Karena frekuensi itemsets tidak diketahui, maka association rules juga tidak dapat dilakukan.

```
rules[ (rules['lift'] >= 6) &

(rules['confidence'] >= 0.8) ]
```

Lift dan Confidence pun tidak dapat diketahui.